

= Two-way contingency tables =

Consideramos un conjunto de observaciones que toman valores en dos dimensiones categóricas,  $i = 1, \dots, I$  y  $j = 1, \dots, J$ . Así, cada observación  $y_i$  está definida en  $\mathcal{I} \times \mathcal{J}$ , donde

$$\mathcal{I} = \{1, 2, \dots, I\}$$

$$\mathcal{J} = \{1, 2, \dots, J\},$$

definiendo así el soporte por  $(y_i)_{i=1}^n$ ,  $n$ -datos.

Un conjunto de ' $n$ ' variables de este tipo puede reacomodarse como una matriz de contingencia de dos dimensiones:

		Dim 2				
		1	2	...	J	
Dim 1	1	$n_{11}$	$n_{12}$	...	$n_{1J}$	$n_{1\cdot}$
	2	$n_{21}$	$n_{22}$	...	$n_{2J}$	$n_{2\cdot}$
	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	
	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	
	I	$n_{I1}$	$n_{I2}$	...	$n_{IJ}$	$n_{I\cdot}$
		$n_{\cdot 1}$	$n_{\cdot 2}$		$n_{\cdot J}$	$n$

$n$  - # de observaciones / datos / variables.


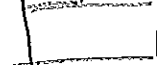




donde 
$$n = \sum_{i=1}^I \sum_{j=1}^J n_{ij}$$

$$= \sum_{i=1}^I n_{i\cdot} = \sum_{j=1}^J n_{\cdot j}$$

donde 
$$n_{i\cdot} = \sum_{j=1}^J n_{ij} \quad \text{y} \quad n_{\cdot j} = \sum_{i=1}^I n_{ij}.$$

con 
$$n_{ij} = \# \{ y_2 : y_{21} \in \{i\} \text{ y } y_{22} \in \{j\} \}.$$

A partir de la table de contingencia, recuperamos las distribuciones marginales de las dos dimensiones:

		Dim 2						
		1	2	...	J			
Dim 1	1					$n_{1.}$		$f_{1.}$
	2					$n_{2.}$		$f_{2.}$
	...					...		...
	I					$n_{I.}$		$f_{I.}$
		$n_{.1}$	$n_{.2}$	...	$n_{.J}$	$n$		
								
		$f_{.1}$	$f_{.2}$	...	$f_{.J}$			

frecuencias  
(absolutas o relativas)

Para la dimension 1, las frecuencias  $\{f_{i.}\}_{i=1}^I$  describen la variabilidad intrínseca a esta dimensión. De igual forma lo hacen  $\{f_{.j}\}_{j=1}^J$  por la dimension 2.

Ambas descripciones de variabilidad, por separado, son extender y corresponden al caso de variabilidad descripta por una distribución multinomial.

▷ Lo que resulta sumamente interesante es describir la variabilidad al interior de la table de contingencia (ranglos o columnas) y su interacción entre los demás casos de cada dimensión.

Para esto, necesitamos definir algunas medidas de utilidad (crítico):

### 1) Risk (Riesgo)

$$\text{Risk} = \begin{array}{l} \text{proporción con una característica} \\ \text{poco deseable} \end{array} = \frac{\#\{y_i: y_{i1} \in \{i^*\} \text{ y } y_{i2} \in \{j^*\}\}}{n}$$
$$= \text{Risk}(\{i^*, j^*\})$$

donde  $\{i^*\}$  y  $\{j^*\}$  son características no deseables en  $I$  y  $J$ , respectivamente.

= se usa en casos de tabla  $2 \times 2$  =

### 2) Riesgo relativo

se define como el cociente de los riesgos entre dos características poco deseables, i.e.

$$\begin{aligned} \text{RR}(\{i^*, j^*\}, \{i', j'\}) &= \\ &= \frac{\text{Risk}(\{i^*, j^*\})}{\text{Risk}(\{i', j'\})} = \\ &= \frac{\#\{y_i: y_{i1} \in \{i^*\}, y_{i2} \in \{j^*\}\}}{\#\{y_i: y_{i1} \in \{i'\}, y_{i2} \in \{j'\}\}} \end{aligned}$$

= Esta medida puede definirse en una sola dimensión, y sea en "i" o en "j" = .

### 3) Riesgo incremental

Porcentaje de incremento del Riesgo  $\{i^*, j^*\}$  relativo al riesgo  $\text{Risk}(\{j', j'\})$ .

$$\Delta \text{RR}(\{i^*, j^*\}, \{i', j'\}) = (\text{RR}(\{i^*, j^*\}, \{i', j'\}) - 1) 100\%$$

#### 4) Momios (Odds)

Proporción de casos con una cierta característica  $\{i^*, j^*\}$  relativo a los casos sin esa característica, i.e.

$$\text{odd} \{i^*, j^*\} = \frac{\# \{y_i: y_{i1} \in \{i^*\}, y_{i2} \in \{j^*\}\}}{\# \{y_i: y_{i1} \notin \{i^*\}, y_{i2} \in \{j^*\}\}}$$

= Se aplica en ambas dimensiones =

#### 5) Momios relativos

~~Proporción~~ <sup>Cociente</sup> de casos con una cierta característica  $\{i^*, j^*\}$  relativo a la proporción de casos con otra característica  $\{i', j'\}$ , en términos de momios; i.e.

$$\begin{aligned} \text{R odd} (\{i^*, j^*\}, \{i', j'\}) &= \frac{\# \{y_i: y_{i1} \in \{i^*\}, y_{i2} \in \{j^*\}\}}{\# \{y_i: y_{i1} \notin \{i^*\}, y_{i2} \in \{j^*\}\}} \bigg/ \frac{\# \{y_i: y_{i1} \in \{i'\}, y_{i2} \in \{j'\}\}}{\# \{y_i: y_{i1} \notin \{i'\}, y_{i2} \in \{j'\}\}} \\ &= \frac{\# \{y_i: y_{i1} \in \{i^*\}, y_{i2} \in \{j^*\}\}}{\# \{y_i: y_{i1} \in \{i'\}, y_{i2} \in \{j'\}\}} \times \frac{\# \{y_i: y_{i1} \notin \{i'\}, y_{i2} \in \{j'\}\}}{\# \{y_i: y_{i1} \notin \{i^*\}, y_{i2} \in \{j^*\}\}} \end{aligned}$$

## Paradox de Simpson

la asociación entre dos variables puede cambiar o incluso invertirse cuando existe otra variable que interactúa fuertemente con ~~otras~~ ambas variables.

Motivación: The Civil Rights Act 1964 (EEUU)

House Vote	Democrat		Republicans	
	Yes	No	Yes	No
Northern	145	9	138	24
Southern	7	87	0	10
Total	152	96	138	34

Senate Vote	Democrat		Republican	
	Yes	No	Yes	No
Northern	45	1	27	5
Southern	1	20	0	1
Total	46	21	27	6

Preguntas:

P1)	% Democrats in House vote	✓	✓	?
P2)	% Republicans	✓	✓	?
P3)	% Democrats in Senate	✓	✓	?
P4)	% Republicans	✓	✓	?

P5) En cada cámara, ¿qué partido votó proporcionalmente más a favor?

Split the results by region?  
Extrud answers accordingly.